Conv 7x7 s2 3→32 : $2 \cdot 7^2 \cdot 3 \cdot 32 \cdot B \cdot (S/2)^2$

Conv 5x5 32→64 : $2 \cdot 5^2 \cdot 32 \cdot 64 \cdot B \cdot (S/4)^2$

Conv 3x3 s2 64→128 : $2 \cdot 3^2 \cdot 64 \cdot 128 \cdot B \cdot (S/8)^2$

Conv 1x1 128→256 : $2 \cdot 128 \cdot 256 \cdot B \cdot (S/8)^2$

Conv 3x3 s2 256→256 : $2 \cdot 3^2 \cdot 256^2 \cdot B \cdot (S/16)^2$

Conv 1x1 256→512 : $2 \cdot 256 \cdot 512 \cdot B \cdot (S/16)^2$

MaxPool 3x2 s2 : $8 \cdot B \cdot 32 \cdot (S/4)^2$

Global AvgPool : $B \cdot 512 \cdot (S/16)^2$

ReLU :

1) $B \cdot 32 \cdot (S/2)^2$
2) $B \cdot 64 \cdot (S/4)^2$
3) $B \cdot 128 \cdot (S/8)^2$
4) $B \cdot 256 \cdot (S/8)^2$
5) $B \cdot 256 \cdot (S/16)^2$
6) $B \cdot 512 \cdot (S/16)^2$
7) $B \cdot 256$

Linear 512→256 : $B \cdot 2 \cdot 512 \cdot 256 + 256B$

Linear 256→100 : $B \cdot 2 \cdot 256 \cdot 100 + 100B$

FLOPs : $2 \cdot 7^2 \cdot 3 \cdot 32 \cdot B \cdot (S/2)^2 + 2 \cdot 5^2 \cdot 32 \cdot 64 \cdot B \cdot (S/4)^2$

$+ 2 \cdot 3^2 \cdot 64 \cdot 128 \cdot B \cdot (S/8)^2 + 2 \cdot 128 \cdot 256 \cdot B \cdot (S/8)^2 +$

$+ 2 \cdot 3^2 \cdot 256^2 B \left(S/16\right)^2 + 2\ 256\ 512 B$

$+ 8B\ 32 \cdot (S/4)^2 + B \cdot 512 \cdot (S/16)^2 + (S/16)$

$+ B \cdot 2 \cdot 512 \cdot 256 + B \cdot 2 \cdot 256\ 100 +$

$+ B\ 32 \cdot (S/2)^2 + B\ 64 \cdot (S/4)^2 + B(S/8)^2 \cdot 128$

$+ B \cdot 256 \cdot (S/8)^2 + B(S/16)^2 \cdot 256 + 512 \cdot B (S/16)^2$

$+ 256B + 100B + B \cdot 256 = 2352 BS^2 + 6400 BS^2 +$

$+ 2304 BS^2 + 1024 BS^2 + 4608 BS^2 +$

$+ 1024 BS^2 + 16 BS^2 + 2 BS^2 + 8 BS^2 +$

$+ 4 BS^2 + 2 BS^2 + 4 BS^2 + BS^2 + 2 BS^2$

$+ 256B + 262144 B \overset{+51200B + 356B}{=} 17751 BS^2 +$

$+$ [illegible] [illegible] $+ 313956 B$

$\underline{FLOPs(B,S)} = 17751 BS^2 + 313956 B$

Память весов свёрток: $7 \cdot 7 \cdot 3 \cdot 32 \cdot 4 + 5 \cdot 5 \cdot 4 \cdot 32 \cdot 64 +$

$+ 3 \cdot 3 \cdot 4 \cdot 64 \cdot 128 + 128 \cdot 256 \cdot 4 + 3 \cdot 3 \cdot 4 \cdot 256 \cdot 256$

$+ 256 \cdot 512 \cdot 4 = 3533184$ байт

Память весов линейных слоев: $4(512 \cdot 256 + 256 +$

$+ 256\ 100 + 100) = 628112$

Память весов: 4161296 байт

Память активаций с учетом исходного

Изображение ($4 \cdot 3BS^2 = 12BS^2$):

Conv 7x7 S2 3→32: $12BS^2 + 4B \cdot \frac{32 \cdot S^2}{4}$
$= 44BS^2$ байт

MaxPool: $12BS^2 + 32BS^2 + 4B \cdot \frac{32}{16} S^2 =$
$= 52BS^2$ байт

2 свертка: $36BS^2$

3 свертка: $36BS^2$

4 свертка: $36BS^2$

5 свертка: $32BS^2$

6 свертка: $24BS^2$

GlobalAvgPool: $20BS^2 + 2048B$

1 Linear: $12BS^2 + 3072B$

2 Linear: $12BS^2 + 4248$

При MaxPool достигается максимум, поэтому Memory(B,S) $= 4161296 + 52BS^2$

Bytes moves(B,S) $= 44BS^2 + 18816 + 64BS^2 +$
$+ 40BS^2 + 24BS^2 + 204800 + 32BS^2 + 24BS^2 +$
$+ 294312 + 16BS^2 + 24BS^2 + 131072 + 32BS^2 +$
$+ 20BS^2 + 2359296 + 8BS^2 + 12BS^2 + 524288$
$+ 16BS^2 + 8BS^2 + 2048B + 3072B + 525312 +$

$+1424B + 102800$ = ~~[illegible]~~

$+ 4161296$ байт $+ 364BS^2 + 8592B$

$\mathrm{Latency}(S, B, \Theta) = \sum_i T_i$, где T_i – время на слой

$T_i = t_{0,i} + \max\left(\frac{F_i}{P}, \frac{Q_i}{W}\right)$, где $t_{0,i}$ – время запуска, F_i – количество операций

P – скорость, W – пропускная способность

Q_i – кол-во байт для перемещения.

$\mathrm{Latency}(S, B, \Theta) =$ ~~[illegible]~~

$= T_0 + \sum_i \max($ ~~[illegible]~~ $\frac{F_i}{P}, \frac{Q_i}{W})$

$\Theta = (T_0, P, W)$

$\mathrm{Energy}(S, B, \Theta) = \bar{P}\,\mathrm{Latency}(S, B, \Theta)$, где $\bar{P}$ – ср. мощность GPU

$\mathrm{Latency}(S, B, \Theta) = T_0 + \max\left(\frac{2352BS^2}{P}, \frac{44BS^2+18}{W}\right)$

$+ \max\left(\frac{8BS^2}{P}, \frac{64BS^2}{W}\right) + \max\left(\frac{16BS^2}{P}, \frac{400BS^2}{W}\right) +$

$+ \max\left(\frac{6400BS^2}{P}, \frac{24BS^2 + 204800}{W}\right) + \max\left(\frac{4BS^2}{P}, \frac{32BS}{W}\right)$

$+ \max\left(\frac{2304BS^2}{P}, \frac{24BS^2 + 294912}{W}\right) +$

$+ \max\left(\frac{2BS^2}{P}, \frac{16BS^2}{W}\right) + \max\left(\frac{1024BS^2}{P}, \frac{24BS^2+131072}{W}\right)$

$$+\max\left(\frac{4BS^2}{P}, \frac{32BS^2}{W}\right)+\max\left(\frac{4608BS^2}{P}, \frac{20BS^2+2^{25}\,9496}{W}\right)$$

$$+\max\left(\frac{BS^2}{P}, \frac{8BS^2}{W}\right)+\max\left(\frac{2BS^2}{P}, \frac{16BS^2}{W}\right)+$$

$$+\max\left(\frac{1024BS^2}{P}, \frac{12BS^2+524288}{W}\right)$$

$$+\max\left(\frac{2BS^2}{P}, \frac{8BS^2+2048B}{W}\right)+$$

$$+\max\left(\frac{262400B}{P}, \frac{3072B+525312}{W}\right)$$

$$+\max\left(\frac{256B}{P}, \frac{2048B}{W}\right)+\max\left(\frac{51300B}{P}, \frac{1424B+102800}{W}\right).$$